

P40 与 L20 推理性能测试报告

Embedding · Reranker · Audio Transcription



1 vs 1	100 次	P50
部署口径：每端 1 个 worker	每组正式请求数	主要延迟指标

报告日期：2026-09-17

测试环境：客户端位于 Asia/Shanghai；P40 使用 HTTPS，L20 使用 HTTP。

结论摘要

L20 在 Reranker 和 Audio 上有显著优势；Embedding 的优势随并发变化，L20 在并发 1 更快，P40 在并发 10 的持续吞吐更高。

1. 测试范围与方法

本报告汇总两端均只部署 1 个 worker 后的重测结果。每种模型分别测试并发 1、5、10，每组发送 100 次请求。预热请求不计入正式结果。所有可比较组均使用相同输入与客户端脚本。

项目	模型 / 输入	请求口径
Embedding	bge-m3	单文本 embedding；脚本内置 10 条英文样本
Reranker	bge-reranker-large	1 query + 10 documents；Top 4；不传 batch_size 扩展参数
Audio	seaco-paraformer-zh	audio/bill_gates-TED.mp3；时长 62.06 秒

关键结论


- Embedding：并发 1 时 L20 QPS 为 P40 的 1.98 倍；并发 5 基本持平；并发 10 时 P40 QPS 为 L20 三轮中位数的 2.57 倍。
- Reranker：L20 在并发 1、5、10 下吞吐分别为 P40 的 2.27、6.08、5.52 倍，且 P50 全面更低。
- Audio：在可公平比较的并发 1 和 5 下，L20 吞吐为 P40 的 2.71 和 2.97 倍。
- Audio 并发 10：P40 服务端 request_limit=5，100 次请求仅 13 次成功，该组不能用于 GPU 性能比较。

说明：P40 经 HTTPS、L20 经 HTTP。对于 Embedding 和 Reranker 这类小请求，TLS、网关与网络路径可能对端到端延迟产生可见影响，因此报告衡量的是当前服务整体表现，不是脱离服务栈的裸 GPU 算力。

2. Embedding 性能

模型：bge-m3。图中实线对应左轴 QPS，虚线对应右轴 P50 延迟。L20 并发 10 使用三轮重测的中位数，以降低偶发长尾对单轮结果的影响。

Embedding 双纵轴曲线



GPU	并发	成功率	QPS	P50 ms	P95 ms	P99 ms
P40	1	100%	11.34	72.69	101.26	799.50
L20	1	100%	22.49	39.49	50.01	379.54
P40	5	100%	28.90	97.37	1034.36	1045.13
L20	5	100%	28.68	91.49	488.87	1466.37
P40	10	100%	32.43	139.46	1800.20	1818.92
L20	10	100%	12.62*	151.88*	1069.67*	7652.70*


* L20 并发 10 为 3 轮各 100 次重测的中位数。三轮 QPS 为 12.56、23.00、12.62；合计吞吐为 14.82 QPS。P50 较稳定，但存在 4 到 8 秒的偶发长尾。

判断：L20 的低并发响应更快；P40 在高并发下吞吐扩展更好。若业务重视稳定性，应同时监控 P95/P99，而不是只看 P50。

3. Reranker 性能

模型：bge-reranker-large。每个请求包含 1 个 query 和 10 个 documents，返回 Top 4。两端统一省略 L20 不兼容的 kwargs.batch_size 扩展参数。

Reranker 双纵轴曲线



GPU	并发	成功率	QPS	P50 ms	P95 ms	P99 ms
P40	1	100%	8.48	100.41	140.50	744.02
L20	1	100%	19.27	46.10	57.23	425.45
P40	5	100%	13.24	300.07	1259.56	1278.76
L20	5	100%	80.49	57.26	94.15	113.96
P40	10	100%	13.39	542.39	2121.71	2129.49
L20	10	100%	73.96	92.64	476.70	478.56

6.08×

80.9%

5

并发 5：L20 吞吐倍数

并发 5：L20 P50 降幅

L20 推荐并发点

判断：L20 在 Reranker 上全面领先。L20 从并发 5 提升到 10 后 QPS 从 80.49 降到 73.96，同时 P50 上升，因此当前最佳客户端并发约为 5。P40 在并发 5 左右已经饱和。

4. Audio Transcription 性能

模型：seaco-paraformer-zh。音频文件 bill_gates-TED.mp3，时长 62.06 秒。RTF 为处理耗时除以音频时长，越低越好。

Audio 双纵轴曲线（P40 并发 10 因限流未绘制）



GPU	并发	成功率	QPS	P50 ms	P95 ms	P99 ms	RTF
P40	1	100%	0.84	1173.86	1364.41	1888.46	0.019
L20	1	100%	2.28	438.36	464.83	600.29	0.007
P40	5	100%	0.93	5319.40	5531.67	6724.90	0.085
L20	5	100%	2.76	1761.76	2206.69	3021.16	0.029
P40	10	13%	无效	无效	无效	无效	无效
L20	10	100%	2.76	3523.05	3861.98	4537.86	0.056

P40 并发 10 返回 HTTP 429：模型 seaco-paraformer-zh-rep0 的 request limit 为 5。快速失败请求会扭曲脚本输出的 QPS 与延迟，因此该组不展示性能数值。

判断：在并发 1 和 5 的有效范围内，L20 吞吐约为 P40 的 2.7 到 3.0 倍。L20 在并发 5 已达到 2.76 QPS；升至并发 10 后吞吐没有增加，P50 从 1.76 秒上升至 3.52 秒。

5. 结论与建议

选型结论

场景	建议	依据
Embedding 低并发	优先 L20	并发 1 时 QPS 约 1.98 倍, P50 低 45.7%
Embedding 高并发	当前配置优先 P40	并发 10 时 P40 QPS 32.43; L20 三轮中位数 12.62
Reranker	优先 L20	全并发区间吞吐和 P50 均显著领先
Audio	优先 L20	有效区间吞吐约为 P40 的 2.7 到 3.0 倍

部署与压测建议

- 对齐模型级 request_limit。若要比对 Audio 并发 10, P40 与 L20 都应配置为至少 10。
- 每个并发点至少重复 3 轮，以轮次中位数作为主结果，并同时报告合计吞吐。
- 固定输入序列与随机种子，避免不同文本长度造成额外波动。
- 服务端同步采集 GPU 利用率、显存、队列长度和批处理大小，以区分 GPU 饱和、调度排队和网络抖动。
- 对小请求增加同网络路径测试，或统一 HTTPS/HTTP 和网关配置，降低传输层差异。
- 生产容量规划同时参考 QPS、P50、P95/P99 和错误率；不以单一平均延迟做结论。

最终结论

在当前单 worker 服务配置下，L20 是 Reranker 与 Audio 的明确优选；Embedding 则取决于并发模式：低并发偏向 L20，高并发持续吞吐偏向 P40。对于 L20 Embedding 并发 10，应继续调查 4 到 8 秒的周期性长尾。

附注：本报告中的测试结果来自客户端端到端观测，包含模型执行、调度、网关、网络和协议开销。API Key 未写入报告。